Phase 4 — Extract

Created	@March 1, 2026 10:49 AM
Tags	

ภาพรวมของ Extract Task

Extract คือการดึงข้อมูลจาก SQL Server แล้วบันทึกเป็น Parquet เพื่อส่งต่อให้ Transform

```
SQL Server (fraud_10k / fraud_100k / fraud_1m)
    ↓ pyodbc
Python dict / PyArrow Table
    ↓ pyarrow.parquet
/tmp/fraud_etl/raw_{key}.parquet
```

อธิบายง่ายๆ คือ ดึงข้อมูลจาก SQL Server ด้วย pyodbc → บันทึกเป็น Parquet → Push timing ผ่าน XCom

> **Parquet คือรูปแบบไฟล์สำหรับเก็บข้อมูลตาราง** เหมือน CSV แต่เก็บข้อมูลแบบ "คอลัมน์" แทนที่จะเป็น "แถว" ทำให้ประมวลผลได้เร็วกว่า และไฟล์เล็กกว่ามาก
>
> ```
> CSV → เก็บทีละแถว
>
> Alice,30,0
> Bob,25,1
> ------------------------------------
> Parquet → เก็บทีละคอลัมน์
>
> [name]     → Alice, Bob
> [age]      → 30, 25
> [is_fraud] → 0, 1
> ```

STEP 1 : สร้างโฟลเดอร์สำหรับเก็บ Parquet

```
mkdir -p /tmp/fraud_etl
ls /tmp/fraud_etl        #รันโค้ดบรรทัดนี้แล้วจะไม่เจออะไรเพราะโฟลเดอร์ว่างเปล่า
```

STEP 2 : สร้างไฟล์ DAG (เฉพาะส่วน Extract ก่อน)

เปิด VS Code สร้างไฟล์ `fraud_etl.py` ในโฟลเดอร์ dags ที่โฟลเดอร์โปรเจค `airflow_credit_card_fraud_detection`

```
fraud_etl.py
```

หรือรันโค้ดนี้ที่ WSL ก็ได้

```
nano ~/airflow/dags/fraud_etl.py
```

STEP 3 : เปิด Airflow Services (ถ้าทำต่อจาก Phase 3 หรือ เปิดไว้อยู่แล้วให้ข้ามไปที่ STEP 4)

Terminal 1:

```
source ~/airflow_env/bin/activate
airflow webserver --port 8080
```

Terminal 2:

```
source ~/airflow_env/bin/activate
airflow scheduler
```

STEP 4 : เขียนโค้ด

วางโค้ดนี้:

```
# ============================================================
============
# fraud_etl.py
# Apache Airflow 2.8.0 + PySpark ETL Pipeline
```

```
# Credit Card Fraud Detection Dataset
# ============================================================
============
import os
import csv
import time
import hashlib

import pyodbc
import pyarrow as pa
import pyarrow.parquet as pq
from datetime import datetime
from dotenv import load_dotenv

from airflow import DAG
from airflow.operators.python import PythonOperator
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, to_timestamp, udf
from pyspark.sql.types import StringType

# ============================================================
=================
# โหลด .env
# ============================================================
=================
load_dotenv(os.path.join(os.path.dirname(__file__), '.en
v'))

# Force JAVA_HOME สำหรับ PySpark ใน Airflow Task
os.environ['JAVA_HOME'] = '/usr/lib/jvm/java-17-openjdk-amd
64'
os.environ['PATH'] = '/usr/lib/jvm/java-17-openjdk-amd64/bi
n:' + os.environ.get('PATH', '')

# ============================================================
=================
# Config
# ============================================================
```

```
=================
MSSQL_CONN = (
    f"DRIVER={{ODBC Driver 17 for SQL Server}};"
    f"SERVER={os.getenv('MSSQL_SERVER')};"
    f"DATABASE={os.getenv('MSSQL_DATABASE')};"
    f"UID={os.getenv('MSSQL_UID')};"
    f"PWD={os.getenv('MSSQL_PWD')}"
)


MYSQL_HOST  = os.getenv('MYSQL_HOST')
MYSQL_PORT  = os.getenv('MYSQL_PORT', '3306')
MYSQL_URL   = f"jdbc:mysql://{MYSQL_HOST}:{MYSQL_PORT}/frau
d_dl"
MYSQL_PROP  = {
    "user":     os.getenv('MYSQL_USER'),
    "password": os.getenv('MYSQL_PWD'),
    "driver":   "com.mysql.cj.jdbc.Driver"
}


JDBC_JAR = os.path.expanduser('~/airflow_credit_card_fraud_
detection/jars/mysql-connector-j-8.0.33.jar')
PARQUET_DIR = "/tmp/fraud_etl"
CSV_LOG     = "/tmp/fraud_etl/timing_log_airflow.csv"
DATASETS    = {"10k": "fraud_10k", "100k": "fraud_100k", "1
m": "fraud_1m"}

# ============================================================
=================
# TASK 1 — EXTRACT
# ============================================================
=================
def extract(dataset_key: str, **kwargs):
    ti       = kwargs['ti']
    table    = DATASETS[dataset_key]
    out_path = f'{PARQUET_DIR}/raw_{dataset_key}.parquet'
```

```
    # --- เริ่มจับเวลา ---
    t_start = time.perf_counter()

    # เชื่อม SQL Server ด้วย pyodbc
    conn   = pyodbc.connect(MSSQL_CONN)
    cursor = conn.cursor()

    # ดึงข้อมูลจาก Table
    cursor.execute(f'SELECT * FROM {table}')
    columns = [desc[0] for desc in cursor.description]  # ชื่
อ Column
    rows    = cursor.fetchall()                          #
ข้อมูลทุกแถว
    conn.close()

    # แปลงเป็น dict
    data = {
        col_name: [row[i] for row in rows]
        for i, col_name in enumerate(columns)
    }

    # แปลงเป็น PyArrow Table แล้วบันทึกเป็น Parquet
    pq.write_table(pa.table(data), out_path)

    # --- หยุดจับเวลา ---
    extract_sec = time.perf_counter() - t_start

    # ส่งค่าผ่าน XCom ไปให้ Task ถัดไป
    ti.xcom_push(key=f'extract_sec_{dataset_key}',  value=e
xtract_sec)
    ti.xcom_push(key=f'parquet_raw_{dataset_key}',  value=o
ut_path)

    print(f'[Extract] {dataset_key}: {len(rows)} rows | {ex
tract_sec:.3f}s')

# ============================================================
=================
```

```
# DAG Definition (Extract Only)
# ============================================================
=================
default_args = {'owner': 'airflow', 'retries': 0}

with DAG(
    dag_id='fraud_etl',
    default_args=default_args,
    schedule_interval=None,
    start_date=datetime(2024, 1, 1),
    catchup=False
) as dag:

    for key in ['10k', '100k', '1m']:
        t_e = PythonOperator(
            task_id=f'extract_{key}',
            python_callable=extract,
            op_kwargs={'dataset_key': key}
        )
```

กด Save (`Cral + S`) หรือ `Ctrl+O` → `Enter` → `Ctrl+X`

STEP 5 : ตรวจว่า Airflow เห็น DAG

ดูผ่าน Web UI โดยเปิดเบราว์เซอร์ไปที่ `http://localhost:8080` แล้วคลิก `fraud_etl` จากนั้น Unpause DAG ขั้นตอนนี้อาจต้องรอสักครู่

STEP 6 : ตรวจสอบว่ามีโฟลเดอร์ /tmp/fraud_etl รึยัง

```
ls -la /tmp/fraud_etl

# ถ้าไม่มีสร้างใหม่เพราะ /tmp จะถูกล้างทุกครั้งที่ restart WSL2
mkdir -p /tmp/fraud_etl
```

STEP 7 : Trigger DAG และ ตรวจสอบผลลัพธ์

1. กด Trigger DAG

2. หลัง Trigger จะเห็น Task แต่ละอันเปลี่ยนสีตามสถานะ

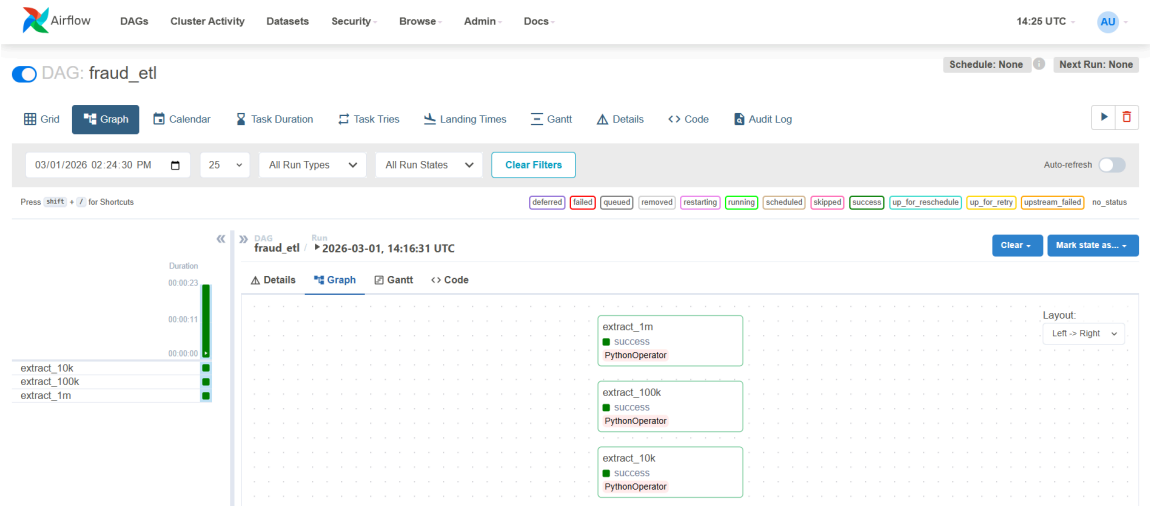

STEP 8 : ตรวจสอบผลลัพธ์

ดูว่าไฟล์ Parquet ถูกสร้างหรือเปล่า:

```
ls -lh /tmp/fraud_etl/
```

ผลที่ควรได้:

```
raw_10k.parquet
raw_100k.parquet
raw_1m.parquet
```

ดูจำนวนแถวใน Parquet ว่าถูกต้องไหม:

```
python3 - <<'EOF'
import pyarrow.parquet as pq
for key in ['10k', '100k', '1m']:
    table = pq.read_table(f'/tmp/fraud_etl/raw_{key}.parque
t')
    print(f'{key}: {table.num_rows} rows, {table.num_column
s} columns')
EOF
```

ผลที่ควรได้:

```
10k:  10000 rows,  23 columns
100k: 100000 rows, 23 columns
1m:   1000000 rows, 23 columns
```

สรุปสิ่งที่ Extract ทำ

ขั้นตอน	รายละเอียด
เชื่อม SQL Server	ผ่าน pyodbc + credentials จาก .env
ดึงข้อมูล	SELECT * FROM fraud_10k / 100k / 1m
แปลงเป็น Parquet	ผ่าน PyArrow บันทึกที่ /tmp/fraud_etl/
จับเวลา	time.perf_counter() ตั้งแต่ connect จนบันทึกเสร็จ
XCom Push	ส่ง extract_sec และ path ของ Parquet ไปให้ Transform