Phase 6 — LOAD

Created	@March 1, 2026 1:40 PM
Tags	

ภาพรวมของ Load Task

```
/tmp/fraud_etl/clean_{key}.parquet
    ↓  PySpark อ่าน Parquet
    ↓  PySpark JDBC เขียนเข้า MySQL
MySQL — fraud_dl.fraud_clean_airflow
```

STEP 1 : เพิ่ม Load function ใน DAG

เพิ่ม Load function **ก่อน** DAG Definition:

```
# ============================================================
====================
# TASK 3 — LOAD
# ============================================================
====================
def load(dataset_key: str, **kwargs):
    ti      = kwargs['ti']
    in_path = ti.xcom_pull(key=f'parquet_clean_{dataset_ke
y}')

    t_start = time.perf_counter()

    spark = (SparkSession.builder
             .appName('fraud_etl')
             .config('spark.jars', JDBC_JAR)
             .getOrCreate())

    df = spark.read.parquet(in_path)
```

```
    (df.write
       .format('jdbc')
       .option('url',      MYSQL_URL)
       .option('dbtable',  'fraud_dl.fraud_clean_airflow')
       .option('driver',   MYSQL_PROP['driver'])
       .option('user',     MYSQL_PROP['user'])
       .option('password', MYSQL_PROP['password'])
       .mode('append')
       .save())

    spark.stop()

    load_sec = time.perf_counter() - t_start

    ti.xcom_push(key=f'load_sec_{dataset_key}', value=load_
sec)

    print(f'[Load] {dataset_key}: {load_sec:.3f}s')
```

STEP 2 : แก้ DAG Definition ให้รวม Load

```
with DAG(
    dag_id='fraud_etl',
    default_args=default_args,
    schedule_interval=None,
    start_date=datetime(2024, 1, 1),
    catchup=False
) as dag:

    for key in ['10k', '100k', '1m']:
        extract_task = PythonOperator(
            task_id=f'extract_{key}',
            python_callable=extract,
            op_kwargs={'dataset_key': key}
        )
        transform_task = PythonOperator(
            task_id=f'transform_{key}',
```

```
            python_callable=transform,
            op_kwargs={'dataset_key': key}
        )
        load_task = PythonOperator(
            task_id=f'load_{key}',
            python_callable=load,
            op_kwargs={'dataset_key': key}
        )


        # Chain: extract → transform → load
        extract_task >> transform_task >> load_task
```

Save

STEP 3 : ตรวจสอบ MySQL ก่อน Trigger

รันโค้ดนี้ใน MySQL:

```
USE fraud_dl;

-- นับแถวทั้งหมด
SELECT COUNT(*) AS total_rows FROM fraud_clean_airflow;
```

ผลที่ควรได้ (ยังว่างอยู่):

```
COUNT(*)
0
```

STEP 4 : Trigger DAG

เปิดเบราว์เซอร์ไปที่ `http://localhost:8080` แล้วคลิก Trigger DAG

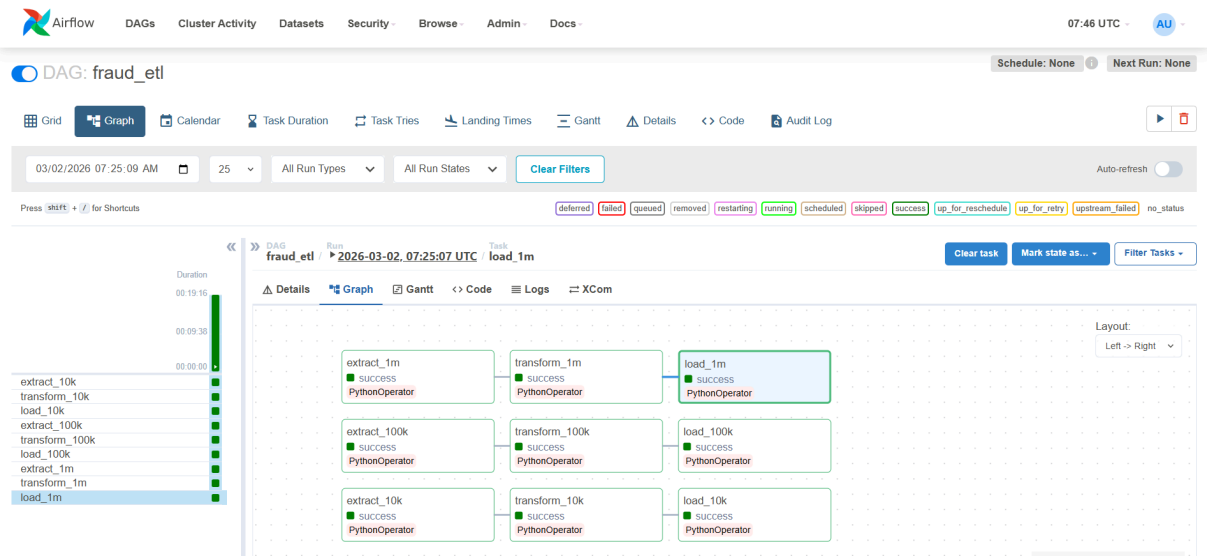

STEP 5 : ตรวจสอบผลลัพธ์หลังรัน

```
-- นับแถวทั้งหมด
SELECT COUNT(*) AS total_rows FROM fraud_clean_airflow;
```

ผลที่ควรได้:

```
COUNT(*)
1110000
```