การเปรียบเทียบประสิทธิภาพ ETL Pipeline 4 แนวทาง ด้วย SSIS, KNIME, Airflow ร่วมกับ PySpark และ Airflow ร่วมกับ Pandas

บทนำ

โครงการนี้เกิดขึ้นจากความต้องการจัดการข้อมูลปริมาณมากที่เกิดขึ้นภายในมหาวิทยาลัย โดยเป็นส่วนหนึ่งของ Senior Project อย่างไรก็ตาม การนำเสนอในครั้งนี้ไม่ได้ครอบคลุมทุกด้านของ Senior Project แต่มุ่งเน้นนำเสนอเฉพาะมุมมองด้าน Processing Performance เพียงด้านเดียวเท่านั้น

การเลือก 4 แนวทางในการทดสอบครั้งนี้มีที่มาจากบริบทการทำงานจริง โดย SSIS ถูกเลือกเนื่องจากมหาวิทยาลัยมี Microsoft License อยู่แล้ว KNIME ถูกเลือกเนื่องจากเป็น Low-code Tool ที่ไม่จำเป็นต้องอาศัยความเชี่ยวชาญด้านการเขียนโค้ด และ Airflow ถูกเลือกโดยกลุ่มนักศึกษาผู้จัดทำซึ่งมีความถนัดด้าน Python มากกว่า C# โดย Airflow ได้ทดสอบร่วมกับ 2 Processing Engine คือ PySpark และ pandas เพื่อเปรียบเทียบว่า Engine ที่ออกแบบมาสำหรับ Big Data โดยเฉพาะอย่าง PySpark จะให้ผลลัพธ์ที่ดีกว่า pandas หรือไม่

การทดสอบทั้งหมดดำเนินการบนเครื่องคอมพิวเตอร์ส่วนบุคคล โดยเครื่องมือทุกตัวได้รับการติดตั้งบน Server ของมหาวิทยาลัย ซึ่งกลุ่มนักศึกษาผู้จัดทำสามารถเข้าถึงและดำเนินการทดสอบได้จากระยะไกล ทำให้สามารถรันงานได้เสมือนการใช้งานจริงในสภาพแวดล้อมขององค์กร โดยใช้ชุดข้อมูล Credit Card Fraud Detection จาก Kaggle ทดสอบใน 3 ขนาด ได้แก่ 10,000 100,000 และ 1,000,000 แถว วัดผลผ่านเวลาที่ใช้จริงในแต่ละขั้นตอน ได้แก่ Extract, Transform และ Load เพื่อให้ได้ข้อสรุปที่เป็นประโยชน์สำหรับการตัดสินใจเลือกใช้แนวทางที่เหมาะสมกับบริบทขององค์กร

สถาปัตยกรรมระบบ

โครงการนี้มีสถาปัตยกรรม 2 รูปแบบ ได้แก่ สถาปัตยกรรมสำหรับการทดสอบที่ใช้จริงในโครงการนี้ และสถาปัตยกรรมระบบสำหรับการใช้งานจริงในมหาวิทยาลัยที่ออกแบบไว้เป็นเป้าหมายปลายทาง โดยผลที่ได้จากการทดสอบในโครงการนี้จะเป็นข้อมูลประกอบการตัดสินใจเลือก ETL Tool ที่เหมาะสมสำหรับนำไปใช้ในระบบจริงต่อไป

1. สถาปัตยกรรมสำหรับการทดสอบ (Test Framework Architecture)

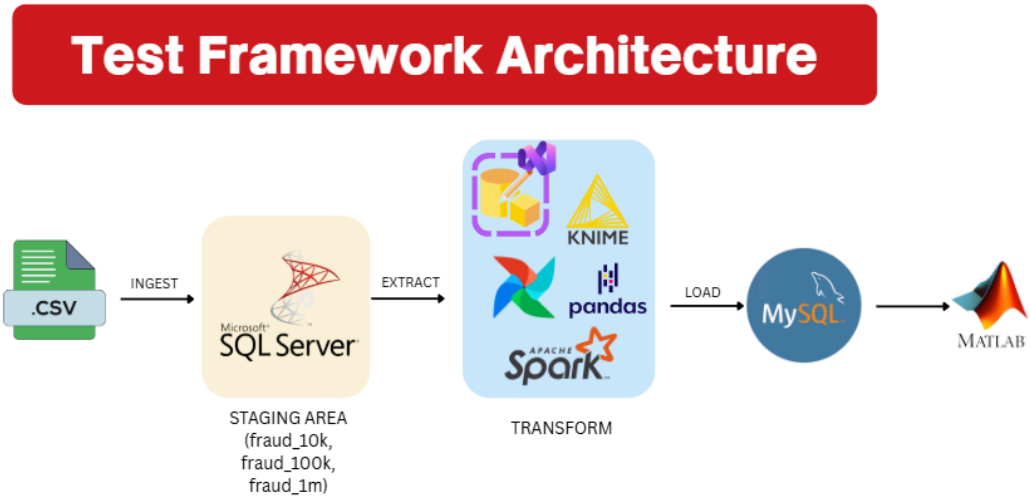

จากภาพสามารถอธิบายได้ดังนี้

1. **Ingest** : นำเข้าข้อมูลจากไฟล์ fraudTrain.csv เข้าสู่ SQL Server เพื่อใช้เป็น Staging Area โดยแบ่งข้อมูลออกเป็น 3 ขนาด ได้แก่ fraud_10k, fraud_100k และ fraud_1m
2. **Extract** : ดึงข้อมูลจาก SQL Server (Staging Area) เพื่อนำไปประมวลผลในแต่ละ ETL Tool ในขั้นตอนถัดไป
3. **Transform** : ประมวลผลข้อมูลด้วย 4 แนวทาง ได้แก่ SSIS, KNIME, Airflow ร่วมกับ PySpark และ Airflow ร่วมกับ pandas โดยการแปลงข้อมูลจะทำเหมือนกันทุกแนวทาง เพื่อให้เกิดความเป็นมาตรฐานเดียวกันของข้อมูล ได้แก่
    - ทำการเข้ารหัสข้อมูลส่วนตัวด้วย SHA-256
    - แปลง Data Type
    - กรองข้อมูลที่ไม่สมบูรณ์ออก
    - เปลี่ยนชื่อคอลัมน์

4. **Load** : บันทึกข้อมูลที่ผ่านการ Transform แล้วลงใน MySQL พร้อมจับเวลาในทุกขั้นตอนเพื่อนำไปวิเคราะห์เปรียบเทียบด้วย MATLAB
5. **Matlab** : นำผลเวลาที่จับได้จากทุกขั้นตอนของทั้ง 4 แนวทางมาวิเคราะห์และแสดงผลในรูปแบบกราฟเพื่อเปรียบเทียบประสิทธิภาพ ETL Pipeline

2. สถาปัตยกรรมระบบสำหรับการใช้งานจริง (Production System Architecture)

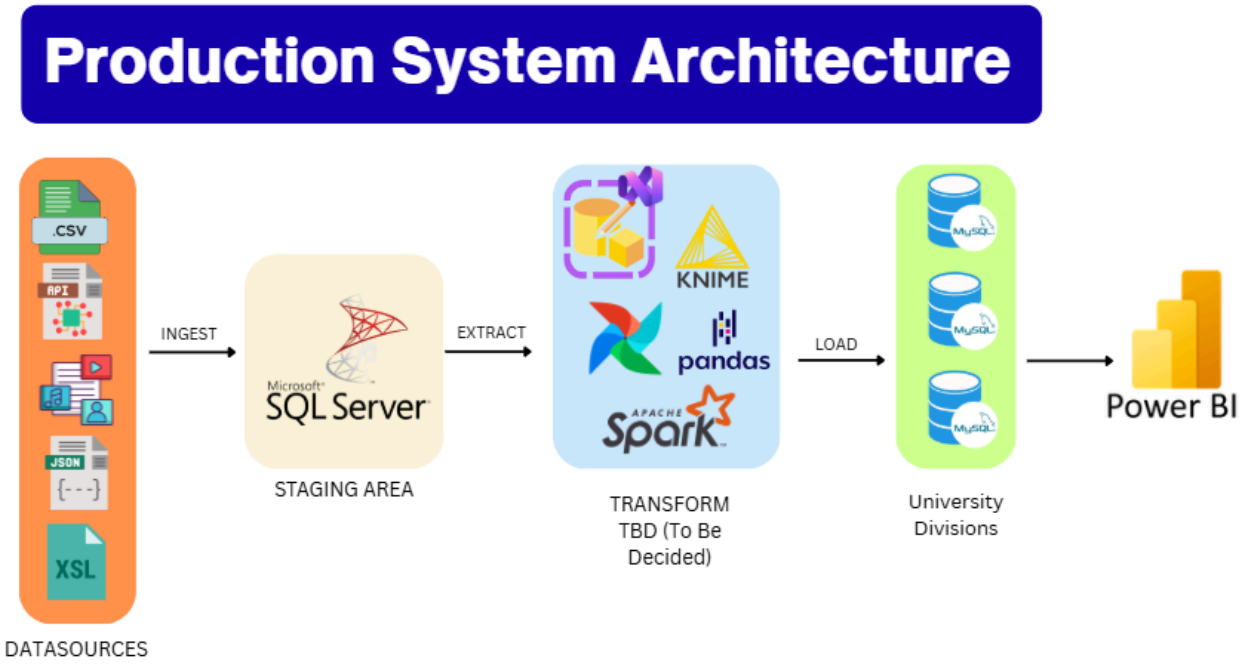

จากภาพเป็นเพียงแนวคิดเท่านั้น ผลที่ได้จากการทดสอบในโครงการนี้จะเป็นข้อมูลประกอบการตัดสินใจเลือก ETL Tool ที่เหมาะสมสำหรับนำไปใช้ในระบบจริงต่อไป อย่างไรก็ตามการตัดสินใจดังกล่าวต้องอาศัยความเห็นจากบุคลากรหลายฝ่ายที่มีส่วนร่วมในการพัฒนาระบบประกอบด้วย

1. **Ingest** : รับข้อมูลจากแหล่งข้อมูลหลากหลายรูปแบบที่เกิดขึ้นจริงในมหาวิทยาลัย ได้แก่ CSV, API, JSON และ XLS เข้าสู่ SQL Server เพื่อใช้เป็น Staging Area และได้มีการออกแบบเพื่อเตรียมการรับข้อมูลประเภทข้อมูลที่ไม่มีโครงสร้าง (unstructured data) ในอนาคตอีกด้วย
2. **Extract** : ใช้ ETL Tool ที่ได้รับการคัดเลือกจากผลการทดสอบ ดึงข้อมูลจาก Staging Area เพื่อนำไปประมวลผล

3. **Transform** : ประมวลผลและทำความสะอาดข้อมูลด้วย ETL Tool ที่คัดเลือกแล้ว ทั้งนี้ขั้นตอน Transform จะครอบคลุมการทำความสะอาดข้อมูล การเข้ารหัสข้อมูลส่วนตัว และการแปลงรูปแบบข้อมูลให้พร้อมใช้งาน โดย Tool ที่จะใช้ยังอยู่ระหว่างการพิจารณาจากผลการทดสอบของโครงการนี้
4. **Load** : กระจายข้อมูลที่ผ่านการประมวลผลแล้วไปยัง MySQL ของแต่ละหน่วยงานในมหาวิทยาลัย และแสดงผลผ่าน Power BI เพื่อเป็นการประกอบการตัดสินใจของผู้บริหารและบุคลากรในมหาวิทยาลัย

สมมติฐาน

ก่อนเริ่มการทดสอบ กลุ่มนักศึกษาผู้จัดทำได้ตั้งสมมติฐานเกี่ยวกับประสิทธิภาพของแต่ละแนวทางไว้ดังนี้

1. **SSIS** : คาดว่าจะมีประสิทธิภาพสูงสุด เนื่องจาก SSIS ใช้ภาษา C# ในการประมวลผล ซึ่งอยู่ในตระกูลเดียวกับภาษา C++ ที่ขึ้นชื่อด้านความเร็วในการประมวลผล จึงคาดว่าจะได้เปรียบด้านความเร็วเหนือแนวทางอื่น
2. **KNIME** : คาดว่าจะมีประสิทธิภาพต่ำที่สุด เนื่องจากเป็น Low-code Tool ที่เน้นความง่ายในการใช้งานมากกว่าประสิทธิภาพ การทำงานผ่านแบบ Low-code อาจมีประสิทธิภาพต่ำกว่าการเขียนโค้ดโดยตรง
3. **Airflow ร่วมกับ PySpark :** คาดว่าจะมีประสิทธิภาพอยู่ในระดับปานกลาง เนื่องจาก PySpark ถูกออกแบบมาสำหรับข้อมูลระดับ Terabyte ขึ้นไป ในขณะที่ข้อมูลที่ใช้ทดสอบมีขนาดสูงสุดเพียง 1 ล้านแถว จึงคาดว่า PySpark จะไม่ได้แสดงศักยภาพเต็มที่ แต่ก็ไม่ช้าเกินไป
4. **Airflow ร่วมกับ pandas** : คาดว่าจะมีประสิทธิภาพใกล้เคียงกับ Airflow ร่วมกับ PySpark เนื่องจากใช้ Orchestrator ตัวเดียวกัน แตกต่างกันเพียง Processing Engine เท่านั้น

สเปกคอมพิวเตอร์ในการทดสอบ

การทดสอบทั้งหมดในโครงการนี้ดำเนินการบนเครื่องคอมพิวเตอร์ที่มีสเปกดังนี้

รายการ	รายละเอียด
Processor	Intel Core i5-1135G7 Gen 11 @ 2.40GHz
RAM	32.0 GB

รายการ	รายละเอียด
ระบบปฏิบัติการ	Windows 11 Home 64-bit

การทดลองในครั้งนี้ดำเนินการทดสอบทั้ง 4 แนวทางบนชุดข้อมูลและเงื่อนไขเดียวกันทุกประการ โดยแต่ละแนวทางจะถูกทดสอบกับข้อมูล 3 ขนาด ได้แก่ 10,000 100,000 และ 1,000,000 แถว พร้อมจับเวลาแยกในแต่ละขั้นตอน ได้แก่ Extract Transform และ Load เพื่อให้ผลการเปรียบเทียบมีความเที่ยงตรงและสามารถนำไปอ้างอิงได้ โดยจะนำเสนอผลการทดลองของ SSIS, KNIME, Airflow ร่วมกับ PySpark และ Airflow ร่วมกับ pandas ตามลำดับ