Phase 1: การเตรียม Dataset และ SQL Server

Created	@February 22, 2026 12:03 PM
Tags	

STEP 1 : Download Dataset จาก Kaggle

1. ไปที่ kaggle.com → สมัครสมาชิกถ้ายังไม่มีบัญชี
2. ค้นหา **"Credit Card Fraud Detection"** หรือเข้าลิงก์นี้เลย: `https://www.kaggle.com/datasets/kartik2112/fraud-detection`
3. กด **Download** → ได้ไฟล์ `fraudTrain.csv`
4. สร้างโฟลเดอร์ `D:\ssis_credit_card_fraud_detection` แล้ววางไฟล์ `fraudTrain.csv` ไว้

STEP 2 : สร้าง Database ใน SQL Server

1. เปิด **SSMS (SQL Server Management Studio) ในโปรเจคนี้ใช้ SQL Server Authentication**

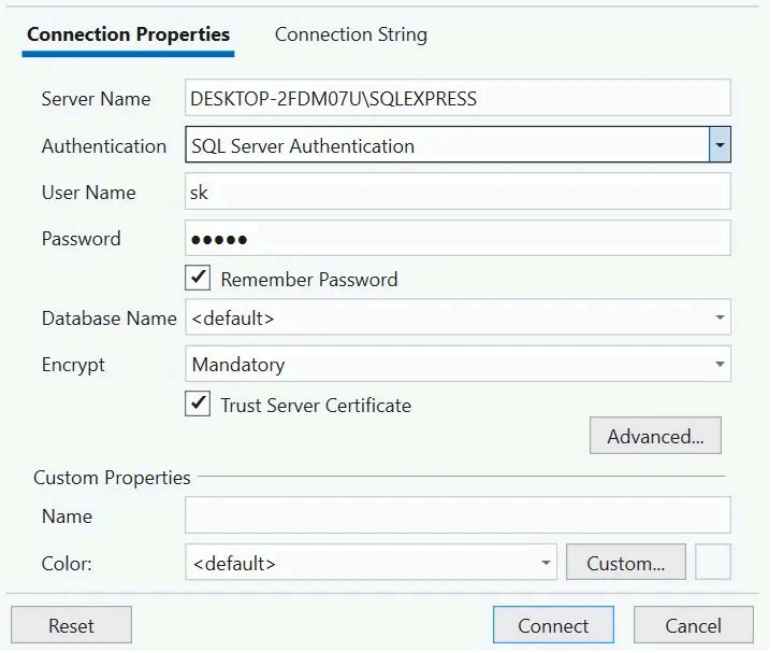

2. เชื่อมต่อ SQL Server → กด **New Query**

3. วาง SQL นี้แล้วกด **Execute (F5)**

```
-- Create Database
CREATE DATABASE frauddb;
GO
```

STEP 3 : วิธี Import CSV ด้วย SSMS Import Flat File Wizard

1. ใน SSMS → **Object Explorer** → คลิกขวาที่ **FraudDB** → **Tasks** → **Import Flat File...**
2. กด **Next** → **Browse** เลือกไฟล์ `fraudTrain.csv` → ตั้งชื่อตารางเป็น `fraud_staging` → กด **Next**
3. หน้า **Preview Data** → กด **Next**
4. หน้า **Modify Columns** → แก้ Data Type ดังนี้:

Column	แก้เป็น
column1	int
merchant	nvarchar(150)
street	nvarchar(150)
job	nvarchar(100)

5. **ติ๊ก Allow Nulls ทุก column** เพราะข้อมูลจริงอาจมีบาง column ที่ว่างเปล่า ถ้าไม่ติ๊กไว้จะ Error ตอน Import → กด **Next** → **Finish**

> 💡 **ข้อดีของวิธีนี้** คือ Wizard จัดการ quoted fields เช่น `"fraud_Rippin, Kub and Mann"` ให้อัตโนมัติ ไม่ต้องแก้ไขอะไรเพิ่ม

ขั้นตอนต่อไปคือตรวจนับแถวใน SSMS ก่อนนะ รันได้เลย:

```
USE frauddb;
SELECT COUNT(*) AS total_rows FROM fraud_staging;
```

ผลลัพธ์ที่ได้:

Results | Messages

	total_rows
1	1296675

STEP 4 : สร้างตาราง 3 ขนาดสำหรับ Benchmark

รัน SQL นี้ใน SSMS ได้เลย:

```
USE frauddb;

-- Batch 1: 10,000 rows
SELECT TOP 10000 * INTO fraud_10k FROM fraud_staging;

-- Batch 2: 100,000 rows
SELECT TOP 100000 * INTO fraud_100k FROM fraud_staging;

-- Batch 3: 1,000,000 rows
SELECT TOP 1000000 * INTO fraud_1m FROM fraud_staging;

-- ตรวจนับทุกตาราง
SELECT COUNT(*) AS rows_10k  FROM fraud_10k;
SELECT COUNT(*) AS rows_100k FROM fraud_100k;
SELECT COUNT(*) AS rows_1m   FROM fraud_1m;
```

ผลลัพธ์ที่ได้:

Results | Messages

	rows_10k
1	10000

	rows_100k
1	100000

	rows_1m
1	1000000

STEP 5 : ดูว่ามีคอลัมน์อะไรบ้างใน dataset

รัน SQL นี้ใน SSMS :

```
USE frauddb;
-- ดู column ทั้งหมดของ fraud_staging
SELECT COLUMN_NAME, DATA_TYPE
FROM INFORMATION_SCHEMA.COLUMNS
WHERE TABLE_NAME = 'fraud_staging'
ORDER BY ORDINAL_POSITION;
```

STEP 6 : เปลี่ยนชื่อคอลัมน์ long เป็น long_col เพราะ `long` เป็น keyword ของ C# ทำให้ BufferWrapper.cs Build ไม่ผ่าน

รัน SQL นี้ใน SSMS ได้เลย:

```
USE frauddb;
EXEC sp_rename 'fraud_staging.long', 'long_col', 'COLUMN';
EXEC sp_rename 'fraud_10k.long', 'long_col', 'COLUMN';
EXEC sp_rename 'fraud_100k.long', 'long_col', 'COLUMN';
EXEC sp_rename 'fraud_1m.long', 'long_col', 'COLUMN';
```

Phase 1 เสร็จสมบูรณ์แล้ว! 🎊